

Roteiro de apresentação

Projeto: Localização Capacitada com Sustentabilidade e Resiliência

Disciplina: Modelos e Algoritmos de Otimização — Prof. Sérgio Queiroz

Grupo: Cláudio Meireles · Felipe Dutra · Lucas Fiche · Pedro Araújo

Duração: 30 minutos de apresentação + 10 minutos de Q&A

Como usar este roteiro

Cada item abaixo corresponde a um slide. Para cada slide há:

- **Tempo sugerido** (totalizando ~28 minutos, com margem de 2 min de transição);
- **Falante recomendado** (4 alunos × ~7 min cada);
- **Fala-base** — não decore, use como referência para encadear ideias;
- **Transição** — frase de passagem para o próximo slide.

Recomendação para o ensaio: rodar o roteiro inteiro 2 vezes (uma lendo, outra falando livre); cronometrar e ajustar; combinar transições entre alunos para evitar pausas longas.

Divisão de tempo por aluno

Aluno	Slides	Tempo (min)	Tópicos
Cláudio Meireles	1-4	~5,5	Capa, agenda, motivação, CFLP clássico
Felipe Dutra	5-7	~6,0	Extensões propostas e instância
Lucas Fiche	8-11	~8,0	Implementação e resultados/mapas
Pedro Araújo	12-15	~8,0	Sensibilidade, discussão, próximos passos
Todos	16	~0,5	Encerramento + Q&A

Roteiro slide a slide

Slide 1. Capa

Falante: Cláudio · **Tempo:** 1.0 min

Fala-base: Boa noite a todos. Somos o grupo Cláudio, Felipe, Lucas e Pedro, da disciplina **Modelos e Algoritmos de Otimização** do professor Sérgio Queiroz. Nosso projeto é uma extensão do **Capacitated Facility Location Problem** — em português, o problema clássico de **localização capacitada de instalações** — incorporando restrições de **sustentabilidade** e **resiliência** de serviço.

↳ transição: "Vamos para a agenda."

Slide 2. Agenda

Falante: Cláudio · **Tempo:** 0.5 min

Fala-base: Vamos passar por: motivação do problema, formulação matemática original e estendida, a instância que construímos com 12 candidatos a CD e 60 clientes, implementação em gurobipy, resultados computacionais com mapas, duas análises de sensibilidade — Pareto de CO₂ e variação de $K_{\min}$ e $D_{\max}$ — e finalmente discussão e próximos passos. No final reservamos 10 minutos para perguntas.

↳ transição: "Começando pela motivação."

Slide 3. 1. Motivação

Falante: Cláudio · **Tempo:** 2.0 min

Fala-base: O CFLP clássico minimiza o custo total de uma rede logística. Mas as decisões reais hoje incluem três pressões que esse modelo **não captura**:

Primeiro, a **agenda ESG** e a regulação climática — empresas têm metas explícitas de redução de CO₂.

Segundo, depois da pandemia e de eventos como o ataque cibernético à JBS ou a paralisação no Canal de Suez, **resiliência** deixou de ser opcional. Depender de um único CD virou risco.

Terceiro, com Amazon Prime e Mercado Livre Full, **SLA** de prazo curto exige proximidade física com o cliente.

Nossa pergunta é direta: **quanto custa, em reais por mês, atender cada um desses requisitos?**

↳ transição: "Para responder, primeiro precisamos do modelo base."

Slide 4. 2. CFLP clássico

Falante: Cláudio · **Tempo:** 2.0 min

Fala-base: Este é o modelo de partida, exatamente como aparece nos exemplos oficiais do Gurobi. Temos duas variáveis de decisão: y_i binária que indica se o CD i é aberto, e x_{ij} contínua entre 0 e 1, fração da demanda do cliente j atendida pelo CD i .

A função objetivo soma o **custo fixo** dos CDs abertos com o **custo de transporte**, proporcional à distância e à demanda. As duas restrições são clássicas: cada cliente precisa ser **totalmente atendido** (soma das frações = 1) e nenhum CD pode **exceder sua capacidade**. É um MILP simples — para nossa instância, apenas 732 variáveis e 72 restrições.

↳ transição: "Agora as três extensões. Felipe."

Slide 5. 3. Extensões propostas (visão)

Falante: Felipe · Tempo: 2.0 min

Fala-base: Obrigado, Cláudio. Adicionamos **três famílias de restrições**, todas **lineares** — então o problema continua sendo MILP, permitindo que o Gurobi resolva exatamente.

E1, sustentabilidade: limitamos as emissões totais de CO₂ do transporte por um **orçamento mensal**. Usamos o fator de **0,062 kg de CO₂ por tonelada-quilômetro**, que é a referência EPA/MMA para frete rodoviário pesado a diesel.

E2, resiliência: cada cliente precisa ser atendido por **pelo menos K diferentes CDs**. E para evitar pseudo-multi-source, limitamos também a **fração máxima** que um CD pode prover de um mesmo cliente em 70%.

E3, SLA: proibimos alocações em pares cuja distância exceda um limite — no nosso caso, 2200 km.

↳ transição: "Agora a formulação matemática completa."

Slide 6. 3.1 Formulação das extensões

Falante: Felipe · Tempo: 2.5 min

Fala-base: Para implementar a resiliência, introduzimos uma **nova variável binária z_{ij}** que vale 1 se o CD i atende o cliente j .

A restrição **$x \leq z$** garante coerência — só podemos enviar fluxo se a alocação está ativada.

A restrição **$z \leq y$** garante que só CDs abertos atendem.

A soma **$\sum z_{ij} \geq K_{\min}$** é o coração do multi-sourcing.

Para o SLA, simplesmente fixamos os limites superiores das variáveis em zero para os pares (i, j) com distância acima do limite — é a forma mais limpa de eliminar essas alocações sem inflar o modelo.

↳ transição: "Próximo: a instância de teste."

Slide 7. 4. Instância

Falante: Felipe · Tempo: 1.5 min

Fala-base: A instância é realista mas tratável: **12 candidatos a CD** em capitais brasileiras — São Paulo, Rio, Belo Horizonte, Curitiba, Porto Alegre, Salvador, Recife, Fortaleza, Brasília, Goiânia, Manaus e Belém. **60 clientes** distribuídos pelo país, sendo 22 capitais e 38 cidades médias geradas por perturbação geográfica.

Custo fixo dos CDs varia entre R\$ 240 mil e R\$ 450 mil por mês; **capacidade**, entre 400 e 900 toneladas/mês. Os dados são lidos de **arquivos CSV** via `data_generator.py`. A demanda total é 2.640 toneladas e a capacidade total 6.700 — folga de 154%, então **a infraestrutura é mais que suficiente**; o desafio é **onde abrir e como alocar**.

↳ transição: "Lucas vai mostrar a implementação."

Slide 8. 5. Implementação — original

Falante: Lucas · Tempo: 2.0 min

Fala-base: Obrigado, Felipe. Aqui está o coração do modelo original em gurobipy. Note como a sintaxe é declarativa: criamos as variáveis com `addVars`, definimos o objetivo com `setObjective`, e as restrições com `addConstrs` usando `generators` Python.

`quicksum` é uma versão otimizada de `sum` para expressões lineares grandes — fundamental para performance.

Resultado: 732 variáveis, 72 restrições, resolve em **0,08 segundos**. 5 CDs abertos: BH, Curitiba, Salvador, Recife e Belém.

↳ transição: "Agora vamos adicionar as extensões."

Slide 9. 5.1 Implementação — extensões

Falante: Lucas · Tempo: 2.0 min

Fala-base: Aqui está o que **muda** entre o modelo original e o estendido — só essas linhas. Bem enxuto.

Adicionamos **z** como matriz binária; em **x** mudamos o ub de 1 para **MAX_SHARE** = 0,7.

(E1) é uma única restrição agregando a soma de emissões.

(E2) são três grupos de restrições — linkando **x** e **z**, garantindo que **z** respeite **y**, e exigindo o multi-sourcing.

(E3) é um loop que zera o limite superior de $x[i, j]$ e $z[i, j]$ quando a distância excede $D_{\max}$ — o Gurobi remove essas variáveis do problema automaticamente.

O modelo cresce para 1.452 variáveis e 1.573 restrições, mas **continua resolvendo em menos de meio segundo**.

↳ transição: "Vamos aos resultados."

Slide 10. 6. Resultados — KPIs

Falante: Lucas · Tempo: 2.5 min

Fala-base: Aqui está a comparação direta. O **custo total** sobe 59,6% — quase R\$ 1,2 milhão a mais por mês. Esse aumento vem inteiramente do **custo fixo**, que dobra: passamos de 5 para 10 CDs abertos.

Mas — e este é o ponto interessante — o custo de transporte cai 29%. Por quê? Porque com mais CDs distribuídos, cada cliente é atendido por instalações mais próximas.

Tonelada-quilômetro total despenca.

Como a emissão de CO₂ é proporcional ao trabalho de transporte, ela cai **na mesma proporção: 29%**. Esse é o ganho ambiental concreto: **290 toneladas de CO₂ por ano evitadas**.

Computacionalmente, o tempo permanece < 0,1 segundo.

↳ transição: "Vamos visualizar isso no mapa."

Slide 11. 6.1 Mapa das alocações

Falante: Lucas · Tempo: 1.5 min

Fala-base: À **esquerda**, o original: 5 CDs vermelhos, cada cliente conectado a apenas **um** CD por uma linha. Note as linhas longas — Manaus atende clientes do Sul, por exemplo.

À **direita**, o estendido: **10 CDs**, e cada cliente tem **múltiplas linhas** saindo dele — o multi-sourcing visualizado. Note que **nenhuma linha cruza grandes distâncias** — o SLA de 2200 km elimina os arcos transcontinentais. A rede fica visivelmente **mais densa e regional**.

É essa redistribuição que produz simultaneamente os ganhos ambientais e a redundância.

↳ transição: "Pedro vai mostrar as análises de sensibilidade."

Slide 12. 7. Pareto CO₂

Falante: Pedro · Tempo: 2.5 min

Fala-base: Obrigado, Lucas. A pergunta natural é: **até onde dá para apertar o orçamento de CO₂?** Variei o orçamento entre 65% e 110% do nível atingido pelo ótimo original e plotei o custo correspondente.

Três observações:

1. Abaixo de **70%**, o problema fica **inviável** — não existe configuração de CDs com multi-sourcing e SLA capaz de atender 60 clientes com tão pouca emissão.

2. A curva é **convexa** — o custo marginal de reduzir a próxima tonelada cresce rapidamente, especialmente abaixo de 60 toneladas por mês.

3. Cada ponto vem rotulado com o número de CDs — metas mais agressivas exigem **mais** CDs abertos, não menos.

Isto é um **insumo gerencial direto**: a curva precifica cada tonelada de CO₂ evitada — argumento concreto para definir uma meta ESG factível.

↳ transição: "Outras sensibilidades."

Slide 13. 7.1 K_{min} e D_{max}

Falante: Pedro · Tempo: 2.0 min

Fala-base: Também variei os outros dois parâmetros. **K_{min}**, o número mínimo de fontes por cliente, é o parâmetro **mais sensível** ao custo: passar de 1 para 3 CDs por cliente **quase dobra** o custo total. **K_{min} = 2** é o ponto de equilíbrio prático — protege contra falha de um único CD sem inflar exageradamente a rede.

D_{max}, a distância máxima, é mais sutil: apertar o limite **aproxima** CDs dos clientes (reduz CO₂ ainda mais), mas força aberturas adicionais. **2200 km** equilibra cobertura nacional com SLA típico de 48-72h.

↳ transição: "Vamos discutir o que isso significa."

Slide 14. 8. Discussão

Falante: Pedro · Tempo: 2.0 min

Fala-base: Nossa leitura econômica:

O driver real do custo de R\$ 1,2 M extras não é o CO₂ — se calcularmos com US\$ 50 por tonelada de CO₂, são apenas US\$ 14,5 mil por ano. **O driver é a resiliência.**

Multi-sourcing protege a operação contra ruptura de um único CD — em um cenário pós-pandemia, isso vale muito.

Computacionalmente a extensão é barata. Para 1.000+ clientes, no entanto, valeria considerar decomposição de Benders ou relaxação Lagrangiana.

A curva de Pareto é a entrega mais valiosa do projeto: transforma uma decisão qualitativa ("queremos ser verdes") em uma decisão quantitativa ("até quanto pagamos por tCO₂?").

↳ transição: "E para fechar."

Slide 15. 9. Limites e próximos passos

Falante: Pedro · Tempo: 1.5 min

Fala-base: Limites do que fizemos:

x_{ij} contínua assume divisibilidade — contratos discretos exigiriam x binário (Generalized Assignment Problem).

Custos lineares — sem economia de escala.

Mono-período e modal único.

Extensões naturais para um próximo trabalho: multi-período com expansão progressiva, multi-modal (rodoviário + ferroviário com fatores de emissão diferentes), e cenários estocásticos para falhas de CD em vez da regra determinística.

↳ transição: "Estamos prontos para perguntas."

Slide 16. Encerramento

Falante: Todos · Tempo: 0.5 min

Fala-base: Obrigado pela atenção. O notebook está no link do Colab nos slides — a implementação completa, executável, com todas as figuras. Estamos prontos para perguntas.

Banco de perguntas prováveis (Q&A; — 10 min)

Estas são perguntas que **esperamos**. Pratique respostas **curtas (60-90 segundos cada)**; se a resposta exigir mais, ofereça detalhar depois para não estender. Quando não souber, diga "**essa é uma boa extensão para um próximo trabalho**" — honestidade vale mais que improviso ruim.

Q1. Por que x_{ij} contínua e não binária?

R: Trata cada cliente como uma demanda mensal grande que pode ser fracionada entre fornecedores — modelagem usual de planejamento estratégico. Para contratos discretos, x_{ij} seria binária (Generalized Assignment Problem) e o modelo cresceria, mas continua resolvível em instâncias deste porte.

Q2. Por que $K_{\min} = 2$ e não 3?

R: Variamos no slide 13: $K_{\min} = 2$ já entrega ~95% do ganho de resiliência (protege contra falha de UM CD), com custo R\$ 1,3 M menor que $K_{\min} = 3$. $K_{\min} = 3$ só faria sentido em cenários de altíssimo risco (cliente estratégico, alta probabilidade de ruptura simultânea).

Q3. E se quisermos meta de zero emissão?

R: Nossa curva de Pareto mostra inviabilidade abaixo de 70% das emissões originais com a frota atual. Zerar emissão exigiria mudança de modal (ferroviário tem fator EF ~80% menor) ou frota elétrica — fora do escopo deste modelo, mas modeladas como restrições adicionais ou novas variáveis no objetivo.

Q4. O modelo é robusto a variação de demanda?

R: Não diretamente — é determinístico. Para incorporar incerteza, dois caminhos: programação estocástica (cenários ponderados) ou otimização robusta (pior caso em uma região de incerteza). Ambas mantêm a estrutura linear, viáveis em Gurobi.

Q5. Qual o ganho real do Gurobi vs CBC ou GLPK?

R: Para esta instância, qualquer solver MILP resolve. Para 1.000+ clientes, Gurobi tipicamente é 5-20× mais rápido por causa de heurísticas de presolve, cortes (MIR, GMI), e branching dirigido — diferença qualitativa quando o tempo passa de minutos para horas.

Q6. Por que distância de Haversine e não rota real?

R: Haversine é uma boa aproximação inicial, especialmente para fluxo interestadual. Substituir por distância de rota (Google Distance Matrix API ou OSRM) é trivial — só muda o dicionário dist. Resultado provável: rotas reais são 10-30% maiores que Haversine, deslocando a curva mas sem mudar a estrutura.

Q7. Por que não usar o solver gratuito do PuLP/SciPy?

R: Por dois motivos: **(a)** a sintaxe declarativa do gurobipy é limpa e comparável; **(b)** licença acadêmica do Gurobi é gratuita via WLS, com performance bem superior a CBC nas instâncias-padrão de MILP. Em escala industrial, comercial.

Q8. Como você modelaria custo de aquisição de CD vs aluguel?

R: Custo fixo f_i pode ser amortizado: $f_i = (\text{CAPEX} \times \text{taxa}) + \text{OPEX}$. Para múltiplos períodos com decisão de abertura em diferentes momentos, y_i passaria a y_i^t com restrição $y_i^t \geq y_i^{t-1}$ (não fecha o que abriu) e f_i^t (CAPEX só no ano de abertura).

Dicas finais para a apresentação

Antes do ensaio

- Revise o notebook Colab — abra ele uma vez sozinho para garantir que executa sem erros (links nos slides 1 e 16).
- Tenha o relatório PDF impresso ou aberto à mão para consultas durante o Q&A.
- Decida quem opera o slide (passa as telas) — geralmente é o falante atual, mas combine.

Durante a apresentação

- **Olhe para a banca**, não para os slides.
- Se travou, **respire** e olhe a próxima transição no roteiro — não improvise muito.
- Use o **mapa das alocações (slide 11)** como peça central — é o resultado mais visual e impactante.
- A **curva de Pareto (slide 12)** é o ponto-alto intelectual — explique devagar, é o que diferencia o trabalho.

Durante o Q&A

- Distribua perguntas — se a primeira é técnica de modelagem, **Felipe ou Lucas** respondem; se é gerencial/discussão, **Cláudio ou Pedro**.
- **Repita a pergunta** antes de responder — garante que a banca ouviu, dá tempo para pensar e estrutura a resposta.
- Se uma pergunta pedir um número, **cite o slide ou abra o relatório** — não chuta valor.

Métricas-chave para decorar (citar de cabeça impressiona)

- Custo: **R\$ 2,04 M → R\$ 3,25 M (+59,6%)**
- CO₂: **82,8 → 58,6 t/mês (-29,2%)**
- CDs: **5 → 10**
- Variáveis: **732 → 1.452**; restrições: **72 → 1.573**
- Tempo Gurobi: **< 0,1 segundo nos dois casos**
- Inviabilidade abaixo de **70%** das emissões originais
- Fator de emissão: **0,062 kg CO₂ / ton-km**